

Análisis Predictivo del Riesgo Respiratorio Usando Datos de Calidad del Aire y Aprendizaje Automático

David Nickolai Parra Ariza

Facultad de Ingeniería, Universidad Nacional de Colombia, Bogotá, Colombia

Autor de correspondencia: Nickolai Parra (correo electrónico: dparraar@unal.edu.co).

Este trabajo se desarrolló como parte de un proyecto académico y no contó con financiación externa.

RESUMEN En ciudades con niveles altos de contaminación atmosférica como Bogotá, las enfermedades respiratorias constituyen un problema relevante de salud pública. Este artículo presenta un análisis predictivo del riesgo respiratorio ambiental a partir de datos históricos de calidad del aire obtenidos de estaciones de monitoreo ambiental. La metodología se fundamenta en la recolección, procesamiento y análisis de condiciones ambientales. Estas variables fueron integradas mediante técnicas de análisis de datos y aprendizaje automático. A partir de estos datos, se desarrollaron modelos predictivos capaces de identificar patrones temporales y espaciales relacionados con el riesgo respiratorio en diferentes zonas de la ciudad. Los resultados incluyen la estructuración de información ambiental por zonas geográficas, la identificación de áreas con mayor propensión al riesgo respiratorio y la generación de visualizaciones espaciales que facilitan la interpretación de los hallazgos. El modelo de mejor desempeño, Random Forest, alcanzó una exactitud de 0.7827 y un F1-score ponderado de 0.7693. Estos resultados evidencian el potencial del uso de datos de calidad del aire y técnicas de inteligencia artificial como herramientas de apoyo para la toma de decisiones en salud pública.

ABSTRACT In cities with high levels of atmospheric pollution such as Bogotá, respiratory diseases constitute a significant public health concern. This article presents a predictive analysis of environmental respiratory risk based on historical air quality data obtained from environmental monitoring stations. The methodology is based on the collection, processing, and analysis of environmental conditions. These variables were integrated using data analysis techniques and machine learning methods. Based on this information, predictive models were developed to identify temporal and spatial patterns associated with respiratory risk across different areas of the city. The results include the structuring of environmental information by geographic zones, the identification of areas with higher respiratory risk propensity, and the generation of spatial visualizations that facilitate the interpretation of the findings. The best-performing model, Random Forest, achieved an accuracy of 0.7827 and a weighted F1-score of 0.7693. These results demonstrate the potential of air quality data and artificial intelligence techniques as decision-support tools for public health planning.

PALABRAS CLAVE análisis espacial, aprendizaje automático, calidad del aire, riesgo respiratorio, salud pública.

INDEX TERMS air quality, machine learning, public health, respiratory risk, spatial analysis.

I. INTRODUCCIÓN

La contaminación atmosférica representa uno de los desafíos ambientales y de salud pública más críticos de la era contemporánea. El aire contaminado genera enfermedades graves del sistema respiratorio y circulatorio, afectando de manera desproporcionada a poblaciones vulnerables como: niños, adultos mayores y personas con enfermedades crónicas preexistentes. La exposición prolongada a estos contaminantes incrementa significativamente el riesgo de desarrollar asma, enfermedad pulmonar obstructiva crónica (EPOC) y cáncer [1]. En este contexto, el monitoreo y la predicción de la calidad del aire no son simplemente herramientas de gestión ambiental, sino mecanismos esenciales para la protección de la salud colectiva.

Entre los contaminantes de mayor relevancia clínica y epidemiológica se encuentran el material particulado ($PM_{2.5}$ y PM_{10}), el dióxido de azufre (SO_2), el monóxido de carbono (CO), los óxidos de nitrógeno (NO y NO_2) y el ozono troposférico (O_3). Debido a su pequeño diámetro, las partículas finas pueden penetrar profundamente en el sistema respiratorio y circulatorio, ocasionando problemas graves de salud [1][2].

El pronóstico de la calidad del aire ha evolucionado considerablemente en las últimas décadas, transitando desde enfoques estadísticos clásicos hasta técnicas avanzadas de inteligencia artificial. Bernacki y Scherer [1] presentan una revisión sistemática de los métodos basados en datos para la predicción de concentraciones de contaminantes, analizando desde modelos estadísticos hasta modelos híbridos. Según este estudio, los modelos basados en aprendizaje profundo emergen como los enfoques más prometedores para la predicción precisa de la calidad del aire.

En particular, el material particulado fino ($PM_{2.5}$) y grueso (PM_{10}) constituye uno de los indicadores más utilizados para evaluar la calidad del aire urbano debido a su estrecha relación con efectos adversos en la salud pública. En primer lugar, Bekkar et al. [2] (en un estudio aplicado en China) destacan que la predicción de concentraciones de material particulado en entornos de ciudades inteligentes es fundamental para anticipar episodios críticos de contaminación y reducir su impacto sanitario mediante sistemas de alerta temprana basados en aprendizaje profundo. Por su parte, Karim et al. [3] (en el contexto de India) subrayan que el PM_{10} , debido a su capacidad de penetrar en el sistema respiratorio, se asocia con: deterioro de la función pulmonar, exacerbación del asma y aumento del riesgo de enfermedades cardiovasculares. Estos contaminantes son medidos tradicionalmente a través de redes de estaciones de monitoreo terrestre que registran concentraciones horarias y diarias, aunque recientemente se han complementado con datos de sensores remotos y variables atmosféricas derivadas de satélites para mejorar la cobertura espacial y la capacidad predictiva.

Así mismo, los análisis epidemiológicos sobre los efectos en salud de la contaminación atmosférica han tendido

históricamente a centrarse en contaminantes individuales, dejando de lado la realidad de que las poblaciones están expuestas simultáneamente a mezclas complejas de múltiples contaminantes. Mwase et al. [4] abordan esta limitación aplicando métodos de clustering no supervisado e investigando los efectos conjuntos de variables ambientales sobre hospitalizaciones por enfermedades respiratorias (ER) y cardiovasculares (ECV) en Sudáfrica. Sus resultados mostraron que la exposición a mezclas con concentraciones elevadas de SO_2 , NO_2 , $PM_{2.5}$ y PM_{10} combinadas con niveles bajos de O_3 incrementan significativamente el riesgo de hospitalización por ER. Este estudio subraya el potencial del aprendizaje automático no supervisado como herramienta para evaluar los efectos conjuntos de mezclas contaminantes.

Además, la creciente disponibilidad de datos provenientes de redes de monitoreo ambiental en ciudades inteligentes ha abierto nuevas posibilidades para desarrollar modelos predictivos que vinculen la calidad del aire con sus efectos sobre la salud. Morales-García et al. [5] destacan que los modelos de predicción basados en aprendizaje automático permiten anticipar la evolución de la contaminación urbana a partir de datos recolectados por redes de sensores IoT (Internet of Things). El estudio, realizado en múltiples ciudades españolas, demostró que los sistemas de predicción de calidad del aire constituyen instrumentos de apoyo para la toma de decisiones por parte de planificadores urbanos y autoridades sanitarias.

En este contexto, aunque la literatura internacional evidencia avances significativos, persisten desafíos asociados a la integración simultánea de variables atmosféricas dentro de un mismo marco predictivo. Por ello, el presente trabajo propone un enfoque integral basado en técnicas de aprendizaje automático para clasificar el nivel de calidad del aire como indicador indirecto de riesgo respiratorio, a partir de concentraciones de contaminantes registradas en estaciones de monitoreo.

II. TRABAJOS RELACIONADOS

- Bekkar et al. en su artículo “*Air-pollution prediction in smart city, deep learning approach*” proponen un modelo híbrido basado en CNN-LSTM para predecir la concentración horaria de PM_{2.5} en Pekín, China; integrando datos históricos de concentraciones de contaminantes. **Metodología:** Implementaron y compararon siete modelos de aprendizaje profundo (LSTM, Bi-LSTM, GRU, Bi-GRU, CNN, CNN-LSTM y CNN-GRU), utilizando diferentes tamaños de lote y métricas. Emplearon interpolación lineal para valores ausentes y selección de características mediante correlación de Pearson [2].
- Karim et al. en su artículo “*Analyzing and predicting PM₁₀ using remote sensing and machine learning: A case study of Delhi, India*” proponen un enfoque integrado de sensores remotos y aprendizaje automático para predecir concentraciones de PM₁₀ en Delhi, India, durante el año 2023. **Metodología:** Utilizaron datos de 39 estaciones de monitoreo y múltiples predictores satelitales: índice de aerosol, humedad atmosférica, gases contaminantes (O₃, NO₂, SO₂, CO), velocidad del viento, temperatura superficial, índices de vegetación, índice de área construida, etc. Evaluaron seis regresores supervisados (MLR, SVR, RFR, SGB, XGB, CBR) y emplearon K-Means para delimitar zonas de alta contaminación [3].
- Mwase et al. en su artículo “*Unsupervised machine learning to investigate the joint effects of SO₂, NO₂, O₃, PM_{2.5} and PM₁₀ on respiratory and cardiovascular hospital admissions in the Vaal Triangle Airshed Priority Area, South Africa*” proponen el uso de métodos de clustering no supervisado (K-means y espectral) para evaluar los efectos conjuntos de mezclas de cinco contaminantes sobre hospitalizaciones por enfermedades respiratorias (ER) y cardiovasculares (ECV) en Sudáfrica. **Metodología:** Imputaron datos faltantes con MICE, escalaron las variables y aplicaron clustering espectral con matriz laplaciana. Posteriormente, introdujeron los clusters obtenidos en modelos de regresión quasi-Poisson [4].
- Morales-García et al. en su artículo “*Reducing Pollution Health Impact With Air Quality Prediction Assisted by Mobility Data*” proponen mejorar la predicción de contaminación atmosférica en ciudades mediante la integración de datos de movilidad vehicular (cámaras de tráfico y sensores) con redes neuronales de grafos (GNN). **Metodología:** Utilizaron datos reales de tres ciudades españolas (Madrid, Bilbao y Cartagena) y generaron datos sintéticos con DoppelGANger para aumentar los conjuntos limitados. Emplearon un GNN con capas Conv-LSTM para capturar dependencias espaciotemporales [5].
- Ahmadianfar et al. en su artículo “*Towards intelligent air quality forecasting using integrated machine learning framework with variational mode decomposition and catboost feature selection*” proponen un marco de aprendizaje automático para la predicción diaria de SO₂ y NO₂ en Changping, China. **Metodología:** Desarrollaron un modelo de aprendizaje extremo (LWKELM) optimizado mediante el algoritmo de búsqueda interior (ISA), aplicando descomposición MVMD sobre ocho variables de entrada para generar funciones de modo intrínseco (IMFs), y empleando el método CatBoost como selector de características para reducir las 400 variables resultantes al 35% más relevante [6].
- Daniyal et al. en su artículo “*Modeling and forecasting air pollution for public health protection based on ML and time series models in Gulf Cooperation Council (GCC) countries*” presentan el primer estudio multipaís para pronosticar concentraciones anuales de PM_{2.5} en las seis naciones del Consejo de Cooperación del Golfo. **Metodología:** Emplearon datos anuales de PM_{2.5} del Banco Mundial para el período 1991–2021. Aplicaron y compararon tres categorías de modelos: tradicionales como ARIMA, no paramétricos como NPAR, y de aprendizaje automático como NNAR. Adicionalmente, construyeron modelos híbridos combinando modelos lineales. El desempeño de los modelos híbridos superó a los individuales [7].
- Singh et al. en su artículo “*Ensemble learning for air quality index prediction: integrating gradient boosting, XGBoost, and stacking with SHAP-based interpretability*” proponen un modelo de conjunto ponderado por votación para la predicción del índice de calidad del aire (ICA). **Metodología:** Emplearon datos horarios de calidad del aire de Taiwán (2016–2024) con seis contaminantes como variables de entrada. Combinaron cuatro algoritmos de impulso por gradiente (Gradient Boosting, CatBoost, XGBoost y LightGBM) con pesos diferenciados, optimizando sus hiperparámetros. Aplicaron valores SHAP (explicaciones aditivas de Shapley) para identificar las variables más influyentes [8].
- Han et al. en su artículo “*Remote sensing-based PM_{2.5} inversion and explainable AI analysis of urban environmental drivers in Harbin*” proponen un marco de dos etapas que integra aprendizaje profundo y machine learning para estimar concentraciones de PM_{2.5} y cuantificar los efectos de la morfología urbana en Harbin, China. **Metodología:** Desarrollaron un modelo de inversión de PM_{2.5} basado en un ST-Transformer con corrección por humedad, usando datos de meteorología y emisiones. Generaron mapas de alta resolución para verano e invierno. Posteriormente, aplicaron XGBoost con SHAP para analizar efectos no lineales e interacciones [9].
- Zhu et al. en su artículo “*Applicability analysis of tree-based ensemble learning for air pollutant prediction models*” proponen un marco de aprendizaje basado en árboles (Random Forest, GBDT y Decision Tree) para la predicción de seis contaminantes (PM_{2.5}, PM₁₀, NO₂, SO₂, CO y O₃) utilizando datos de cuatro municipios de

China (2021-2024). **Metodología:** Emplearon datos horarios de contaminantes y variables meteorológicas (temperatura, humedad, velocidad del viento, precipitación, presión), normalizaron con Z-score, aplicaron codificación seno-coseno para ciclos diarios/mensuales, construyeron características derivadas (interacciones como Temperatura×Viento) Realizaron selección de características en dos etapas. Optimizaron hiperparámetros mediante búsqueda en cuadrícula y evaluaron con RMSE, MAE y R². Utilizaron SHAP (TreeExplainer) para interpretar los modelos [10].

- Telesca y Rondinone en su artículo “*Ensemble Machine Learning Model to Analyse the Correlation Between Environmental Features and Respiratory Admissions in the Emergency Room*” proponen un modelo de aprendizaje por conjuntos (Random Forest, XGBoost, AdaBoost) para analizar la asociación entre ingresos diarios por enfermedades respiratorias en urgencias y factores ambientales (temperatura, presión atmosférica, humedad, CO, O₃, PM₁₀, NO₂) en Bari, Italia (2013-2023). **Metodología:** Aplicaron una media móvil exponencial de 7 días para estabilizar la serie temporal, optimizaron los hiperparámetros con optimización bayesiana y evaluaron los modelos con R² y MAE. Utilizaron SHAP para interpretación global y LIME para análisis local [11].

A. ANÁLISIS COMPARATIVO

De la revisión de la literatura se desprenden tres enfoques predominantes en la aplicación de técnicas de aprendizaje automático para la predicción de la calidad del aire y su relación con efectos en la salud: (i) modelos de aprendizaje profundo para la predicción de concentraciones de contaminantes, (ii) métodos de clustering no supervisado para el análisis de mezclas de contaminantes, y (iii) sistemas de aprendizaje por conjuntos con técnicas de interpretabilidad (SHAP, LIME) para la identificación de variables críticas.

En el primer grupo, Bekkar et al. [2] demostraron que los modelos híbridos CNN-LSTM superan a los demás. Morales-García et al. [5] extendieron este enfoque incorporando datos de movilidad vehicular y datos sintéticos, logrando reducciones de error. Por su parte, Han et al. [9] combinaron un ST-Transformer con restricciones físicas. Estos trabajos coinciden en que la integración de múltiples fuentes de datos (satelitales, meteorológicos, de movilidad y morfológicos) mejora sustancialmente la precisión predictiva, aunque con elevados costos computacionales y limitada transferibilidad entre regiones.

En el segundo grupo, Mwase et al. [4] aplicaron clustering espectral para analizar mezclas de cinco contaminantes y su efecto conjunto sobre hospitalizaciones respiratorias en Sudáfrica. Karim et al. [3] utilizaron K-Means para delimitar zonas de alta contaminación en Delhi y evaluaron seis regresores supervisados, siendo CatBoost el de mejor desempeño. Estos estudios evidencian que el aprendizaje no supervisado permite superar la limitación de los análisis

univariados al considerar mezclas realistas de contaminantes, pero carecen de validación externa.

En el tercer grupo, Singh et al. [8] propusieron un conjunto ponderado de cuatro algoritmos de boosting (Gradient Boosting, CatBoost, XGBoost, LightGBM) con interpretabilidad SHAP para predecir el índice de calidad del aire en Taiwán. Zhu et al. [10] compararon Random Forest, GBDT y Decision Tree para seis contaminantes, encontrando que RF es óptimo para material particulado mientras que DT compete bien para O₃. Telesca y Rondinone [11] aplicaron XGBoost con SHAP y LIME para predecir ingresos diarios por enfermedades respiratorias en Bari. Ahmadianfar et al. [6] y Daniyal et al. [7] complementaron este grupo al demostrar que la descomposición de señales (MVMD) y los modelos híbridos (ARIMA-NNAR) mejoran el rendimiento en escenarios con series temporales complejas.

En conjunto, la literatura evidencia una clara tendencia hacia la combinación de modelos de conjunto (ensemble) con técnicas de explicabilidad (SHAP, LIME) para dotar de transparencia a las predicciones y facilitar su uso en políticas públicas. Sin embargo, persisten desafíos comunes: la mayoría de los estudios se limitan a una única ciudad o región, empleando horizontes temporales cortos. Además, la mayoría se centra en la predicción de la concentración de contaminantes más que en la predicción directa del riesgo de enfermedad respiratoria.

B. CONCLUSIÓN METODOLÓGICA

A partir de la comparación de los diez trabajos relacionados, se identifica que la metodología más efectiva para clasificar el nivel de riesgo respiratorio ambiental a partir de datos de calidad del aire es la combinación de modelos de aprendizaje por conjuntos basados en árboles (específicamente Random Forest y XGBoost) con técnicas de explicabilidad como SHAP y LIME. Esta conclusión se sustenta en que dichos modelos logran un equilibrio superior entre precisión predictiva y transparencia interpretativa, permitiendo identificar umbrales críticos de contaminantes y variables meteorológicas asociados al riesgo respiratorio. Aunque los modelos de aprendizaje profundo (CNN-LSTM, GNN) alcanzan precisiones ligeramente mayores en la predicción de concentraciones, su falta de interpretabilidad y alto costo computacional los hacen menos adecuados para aplicaciones en salud pública donde se requiere justificar decisiones y establecer alarmas tempranas basadas en variables explicativas claras.

III. METODOLOGÍA

El presente estudio adopta el proceso estándar entre industrias para la minería de datos: **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) como marco metodológico. CRISP-DM es un proceso cíclico e iterativo compuesto por seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Su selección se justifica por tres razones: primero, está diseñado explícitamente para proyectos de analítica predictiva con datos reales, lo cual se ajusta al carácter de este trabajo; segundo, su estructura iterativa permite retornar a fases anteriores cuando los datos o los resultados lo exigen, algo habitual en series temporales ambientales con registros faltantes o irregulares; tercero, es el marco de referencia más ampliamente adoptado en la literatura de aprendizaje automático aplicada a calidad del aire y salud pública, tal como se evidencia en los trabajos revisados en la sección anterior [3][8][10][11].

A. FASE 1: COMPRENSIÓN DEL NEGOCIO

El objetivo central del proyecto es clasificar el nivel de riesgo respiratorio ambiental en distintas zonas de Bogotá a partir del ICA. La variable objetivo es el **nivel de riesgo respiratorio por zona geográfica**, definido a partir de la concentración de contaminantes registrada en las estaciones de monitoreo. El propósito final del modelo es servir como herramienta de apoyo a la toma de decisiones en salud pública, permitiendo identificar áreas críticas y anticipar episodios de alta exposición.

B. FASE 2: COMPRENSIÓN DE LOS DATOS

Los datos empleados provienen de la **Red de Monitoreo de Calidad del Aire de Bogotá** (RMCAB), operada por la Secretaría Distrital de Ambiente [12]. Esta red registra, con resolución horaria, las concentraciones de los principales contaminantes atmosféricos en múltiples estaciones distribuidas por la ciudad. Las variables recolectadas comprenden: material particulado fino ($PM_{2.5}$), material particulado grueso (PM_{10}), dióxido de azufre (SO_2), monóxido de carbono (CO), óxidos de nitrógeno (NO y NO_2) y ozono troposférico (O_3). Estas variables fueron seleccionadas por su reconocida relevancia clínica y epidemiológica, en coherencia con los contaminantes analizados en los trabajos relacionados. Como parte de esta fase, se realiza un análisis exploratorio de los datos que incluye: la inspección de distribuciones, la identificación de valores atípicos y la caracterización de los patrones temporales presentes en las series.

C. FASE 3: PREPARACIÓN DE LOS DATOS

El análisis exploratorio revela que el portal RMCAB publica los datos con imputación previa, por lo que no se registran valores faltantes en los contaminantes de interés. Sin embargo, se identifican valores físicamente inválidos (concentraciones negativas) atribuibles a errores instrumentales o de transmisión. Como primer paso del preprocesamiento, se inicia una etapa de **limpieza de**

outliers mediante filtrado por umbral físico (valor ≥ 0) y por rango intercuartílico (IQR) para valores extremos. A continuación, las variables continuas se normalizan mediante **estandarización Z-score** para garantizar la comparabilidad entre contaminantes de distintas escalas de magnitud, siguiendo la práctica de Zhu et al. [10]. Con el fin de preservar la naturaleza cíclica de la dimensión temporal, las variables de hora del día y mes del año se codifican mediante **transformación seno-coseno**, técnica que evita la discontinuidad que introduciría una codificación ordinal simple.

D. FASE 4: MODELADO

Con base en la conclusión metodológica derivada de la revisión de la literatura, se seleccionan dos algoritmos de aprendizaje por conjuntos basados en árboles de decisión: **Random Forest** (RF) y **Extreme Gradient Boosting** (XGBoost).

Random Forest es un método de conjunto que construye un número determinado de árboles de decisión de forma paralela, cada uno entrenado sobre una muestra aleatoria con reemplazo del conjunto de datos (bootstrap) y usando un subconjunto aleatorio de variables en cada nodo de división. La predicción final se obtiene promediando los resultados de todos los árboles, lo cual reduce la varianza y aumenta la robustez frente al sobreajuste. Su selección está respaldada por Zhu et al. [10], quienes demostraron que RF ofrece el mejor desempeño para la predicción de material particulado entre los modelos basados en árboles.

XGBoost es un método de conjunto secuencial que construye árboles de forma iterativa, donde cada nuevo árbol corrige los errores residuales del modelo anterior mediante descenso por gradiente. Su eficiencia computacional, su capacidad para manejar valores faltantes internamente y su regularización integrada lo hacen especialmente adecuado para conjuntos de datos ambientales con ruido [8][9]. Telesca y Rondinone [11] validaron su uso específicamente en el contexto de la predicción de ingresos hospitalarios por enfermedades respiratorias.

Los hiperparámetros de ambos modelos se optimizan mediante búsqueda en cuadrícula (grid search) con validación cruzada de k-pliegues ($k = 5$), garantizando que la evaluación del rendimiento sea independiente del conjunto de entrenamiento. El conjunto de datos se divide en 80 % para entrenamiento y 20 % para prueba.

E. FASE 5: EVALUACIÓN

El rendimiento de los modelos se cuantifica mediante métricas estándar para clasificación multiclase: exactitud global (**Accuracy**), F1-score ponderado (**F1-weighted**), **precisión** y exhaustividad (**Recall**) por clase. Adicionalmente, se construye una **matriz de confusión** para cada modelo con el fin de analizar los patrones de error por categoría.

Para dotar al modelo de interpretabilidad, se aplican valores **SHAP** (SHapley Additive exPlanations). SHAP es un

método de explicabilidad basado en la teoría de juegos cooperativos de Shapley, que asigna a cada variable de entrada una contribución marginal a la predicción. Su uso permite identificar qué contaminantes ejercen mayor influencia sobre el riesgo respiratorio predicho, tanto a nivel global (patrones generales del modelo) como local (predicción individual por zona). Esta técnica ha sido validada en contextos idénticos al presente estudio por Singh et al. [8], Han et al. [9], Zhu et al. [10], y Telesca y Rondinone [11].

F. FASE 6: DESPLIEGUE

Los resultados del modelo se materializan mediante **visualizaciones espaciales** georreferenciadas que mapean el nivel de propensión al riesgo respiratorio sobre las distintas zonas geográficas de Bogotá, integrando la información de las estaciones de la RMCAB con los valores predichos. Estas representaciones buscan comunicar los hallazgos de forma accesible para planificadores urbanos y autoridades sanitarias, en la línea propuesta por Morales-García et al. [5].

IV. IMPLEMENTACIÓN

El código fuente completo, los datos procesados y las visualizaciones generadas están disponibles en el repositorio público del proyecto:

<https://github.com/NickolaiParra/respiratory-risk-bogota>

A. ENTORNO Y HERRAMIENTAS

La implementación se desarrolló en **Python 3.11** sobre un entorno virtual aislado. Las bibliotecas principales empleadas fueron: **pandas** y **NumPy** para la manipulación y estructuración de datos tabulares; **scikit-learn** para los procedimientos de preprocesamiento, validación cruzada y entrenamiento del modelo Random Forest; **XGBoost** para el modelo de gradient boosting; **SHAP** para el análisis de interpretabilidad; **Matplotlib** y **Seaborn** para la generación de gráficas estadísticas; y **Leaflet.js** para la construcción del mapa de riesgo georreferenciado interactivo.

B. CARGA Y EXPLORACIÓN DE DATOS RMCAB

Dado que el portal oficial de la RMCAB no dispone de una API pública ni de un mecanismo de exportación masiva, se desarrolló un script de recolección automatizada mediante técnicas de **web scraping**. El script realiza peticiones HTTP diarias a la URL:

<http://rmcab.ambientebogota.gov.co/Report/HourlyReports>

Este script extrae los registros horarios embebidos en formato JSON dentro del atributo *onclick* de los elementos de la página, e itera sobre el rango temporal comprendido entre el 1 de enero de **2024** y el 31 de diciembre de **2025**. El conjunto de datos resultante comprende registros horarios de 19 estaciones de monitoreo distribuidas en Bogotá, con las siguientes variables: PM_{2.5}, PM₁₀, SO₂, CO, NO, NO₂ y O₃. El dataset consolidado fue almacenado en formato CSV comprimido para su disponibilidad en el repositorio del proyecto [13].

	A	B	C	D
1	fecha_hora	estacion	contaminante	valor
2	2024-01-01T01:00:00	centro_de_alto_rendimiento	PM10	17.12102
3	2024-01-01T02:00:00	centro_de_alto_rendimiento	PM10	24.2629
4	2024-01-01T03:00:00	centro_de_alto_rendimiento	PM10	19.52771
5	2024-01-01T04:00:00	centro_de_alto_rendimiento	PM10	28.35594
6	2024-01-01T05:00:00	centro_de_alto_rendimiento	PM10	26.51388
7	2024-01-01T06:00:00	centro_de_alto_rendimiento	PM10	36.19727
8	2024-01-01T07:00:00	centro_de_alto_rendimiento	PM10	25.93022
9	2024-01-01T08:00:00	centro_de_alto_rendimiento	PM10	30.05538
10	2024-01-01T09:00:00	centro_de_alto_rendimiento	PM10	32.13697
11	2024-01-01T10:00:00	centro_de_alto_rendimiento	PM10	25.11105
12	2024-01-01T11:00:00	centro_de_alto_rendimiento	PM10	27.46856
13	2024-01-01T12:00:00	centro_de_alto_rendimiento	PM10	28.19806
14	2024-01-01T13:00:00	centro_de_alto_rendimiento	PM10	26.46935
15	2024-01-01T14:00:00	centro_de_alto_rendimiento	PM10	22.33438
16	2024-01-01T15:00:00	centro_de_alto_rendimiento	PM10	21.48351

FIGURE 1. Muestra representativa del conjunto de datos recolectado.

Como parte de la exploración inicial, se analizó la **distribución de registros** por estación. La Fig. 2 muestra que Tunal y Centro de Alto Rendimiento concentran la mayor cobertura temporal con más de 300.000 registros cada una, mientras que Carvajal-Sevillana presenta la menor densidad con aproximadamente 90.000 registros.




FIGURE 2. Distribución de registros por estación de monitoreo.

Luego, se identificaron los porcentajes de **valores faltantes** por variable. El análisis arrojó un 0 % de ausencias para todos los contaminantes de interés (PM_{10} , $PM_{2.5}$, CO, O_3 , NO, NO_2 y SO_2), lo que indica que el portal RMCAB aplica un proceso de imputación previo a la publicación de los datos.

Así mismo, se caracterizaron los **patrones temporales** mediante visualizaciones de series de tiempo. Durante este análisis se identificaron valores físicamente inválidos en diversas variables, incluyendo concentraciones negativas de material particulado y gases, los cuales corresponden a errores instrumentales o de transmisión. La Fig. 3 ilustra este fenómeno para $PM_{2.5}$ en la estación Centro de Alto Rendimiento como caso representativo. Dichos valores fueron tratados como *outliers* en la fase de preprocesamiento y aplicados de forma transversal a todos los contaminantes.




FIGURE 3. Serie de tiempo diaria de $PM_{2.5}$, estación Centro de Alto Rendimiento

C. PREPROCESAMIENTO

El preprocesamiento comprendió cuatro etapas sobre los contaminantes de interés: (i) **limpieza de outliers** por umbral físico (valor ≥ 0) e IQR; (ii) **pivoteo a formato ancho**; (iii) **codificación seno-coseno** de hora del día y mes del año; y (iv) **normalización Z-score** sobre los siete contaminantes.

Tras la limpieza, el dataset quedó conformado por 1,893,867 registros en formato largo, los cuales fueron reestructurados mediante una operación de pivoteo a formato ancho, resultando en 328,463 observaciones. Se obtuvo una fila por combinación estación-hora y una columna por contaminante. Las variables continuas fueron normalizadas mediante estandarización Z-score, obteniendo distribuciones con media cero y desviación estándar unitaria. Con el fin de preservar la naturaleza cíclica de la dimensión temporal, la hora del día y el mes del año fueron codificados mediante transformación seno-coseno. La Fig. 4 presenta una muestra representativa del dataset resultante.

Muestra representativa del dataset procesado (primeras 10 filas)

fecha_hora	estacion	PM10	PM2.5	CO	O3NO	NO	NO2	SO2	hora_sin	hora_cos	mes_sin	mes_cos
2024-01-01 01:00	bolivia	0.123	0.757	-0.213	-0.797	0.744	-1.211	-0.835	0.259	0.966	0.5	0.866
2024-01-01 01:00	centro de alto rendimiento	-0.498	-1.245	-0.396	-0.406	-0.6	0.615	-0.25	0.259	0.966	0.5	0.866
2024-01-01 01:00	ciudad bolivar	2.53	3.41	1.806	-0.756	0.743	0.762	0.645	0.259	0.966	0.5	0.866
2024-01-01 01:00	colina	0.451	1.027	1.018	-0.89	0.904	1.116	0.821	0.259	0.966	0.5	0.866
2024-01-01 01:00	fontibon	0.483	1.957	0.267	-0.246	0.652	-0.243	-0.174	0.259	0.966	0.5	0.866
2024-01-01 01:00	guaymaral	0.398	0.661	0.659	-0.876	0.297	0.023	-0.835	0.259	0.966	0.5	0.866
2024-01-01 01:00	jazmin	0.142	0.201	0.215	-0.358	-0.458	0.321	0.148	0.259	0.966	0.5	0.866
2024-01-01 01:00	kennedy	1.692	-1.141	1.138	-0.499	-0.258	-0.004	1.831	0.259	0.966	0.5	0.866
2024-01-01 01:00	las ferias	0.161	1.441	0.205	-0.55	-0.349	0.016	-0.835	0.259	0.966	0.5	0.866
2024-01-01 01:00	minambiente	-0.029	1.094	0.164	-0.39	-0.575	-0.347	-0.835	0.259	0.966	0.5	0.866

FIGURE 4. Muestra representativa del dataset procesado

D. ENTRENAMIENTO DE MODELOS

Como paso previo al entrenamiento, se construyó la variable objetivo mediante el cálculo del Índice de Calidad del Aire (ICA) siguiendo los breakpoints oficiales de la Resolución 2254 de 2017 del Ministerio de Ambiente y Desarrollo Sostenible [14]. Para cada contaminante se calcularon promedios móviles según la ventana temporal definida por la norma (24h para PM_{10} y $PM_{2.5}$, 8h para CO y O_3 , 1h para SO_2 y NO_2), se obtuvo el sub-ICA mediante interpolación lineal, y se tomó el máximo entre contaminantes como ICA horario por estación. El resultado fue clasificado en cinco categorías ordinales: Buena (0-50), Aceptable (51-100), Dañina a grupos sensibles (101-150), Dañina (151-200) y Muy dañina a la salud (201-500).

Se entrenaron dos modelos de clasificación: **Random Forest** y **XGBoost**. Para ambos se realizó una búsqueda de hiperparámetros mediante Grid Search con validación cruzada de 5 pliegues ($k=5$), utilizando F1-weighted como métrica de optimización, adecuada para distribuciones de clases desbalanceadas. Los modelos entrenados fueron serializados para su posterior uso en la fase de evaluación e inferencia.

La distribución resultante de categorías se presenta en la Tabla I, evidenciando un desbalance de clases que justifica el uso de F1-weighted como métrica de optimización.

TABLE I

DISTRIBUCIÓN DE REGISTROS POR CATEGORÍA ICA

Categoría	Rango ICA	Registros
Buena	0-50	160,137
Aceptable	51-100	150,973
Dañina a grupos sensibles	101-150	10,042
Dañina	151-200	4,425
Muy dañina	201-500	3,268

E. EVALUACIÓN

Los modelos fueron evaluados sobre un conjunto de prueba correspondiente al 20% del dataset (65,693 observaciones), reservado mediante división estratificada. La Tabla II presenta las métricas globales de ambos modelos.

TABLE II
COMPARACIÓN DE MÉTRICAS DE EVALUACIÓN

Modelo	Accuracy	F1-weighted	Precisión	Recall
Random Forest	0.7827	0.7693	0.7855	0.7827
XGBoost	0.7770	0.7658	0.7702	0.7770

Random Forest obtuvo un desempeño superior en todas las métricas, con un F1-weighted de 0.7693 frente a 0.7658 de XGBoost. Ambos modelos presentaron un rendimiento sólido en las categorías mayoritarias Buena y Aceptable, con F1-score por clase superior a 0.79. Sin embargo, el desempeño en categorías minoritarias (Dañina y Muy dañina) fue limitado, con recall cercano a cero para la categoría Dañina, resultado esperado dado el desbalance de clases evidenciado en la Tabla I. La Fig. 5 presenta las **matrices de confusión** de ambos modelos.




FIGURE 5. Matrices de confusión Random Forest y XGBoost

F. INTERPRETABILIDAD SHAP

Con el fin de garantizar la transparencia del modelo, se aplicó el método **SHAP** (SHapley Additive exPlanations) sobre el modelo XGBoost para cuantificar la contribución individual de cada variable a las predicciones. El análisis se realizó sobre una muestra aleatoria de 2,000 observaciones. Este método fue aplicado a XGBoost debido a que TreeExplainer

de SHAP es nativamente compatible con XGBoost mediante su estructura de árboles internos, lo que permite un cálculo exacto y eficiente de los valores de Shapley. Para Random Forest, SHAP también usa TreeExplainer, pero con mayor costo computacional sobre conjuntos grandes. Dado que ambos modelos comparten las mismas variables de entrada y producen importancias consistentes entre sí, el análisis sobre XGBoost es representativo del comportamiento general del sistema.

La Fig. 6 presenta la importancia global de características calculada como el promedio del valor absoluto SHAP sobre todas las clases. PM_{2.5} resultó ser el predictor dominante con un valor medio de 0.58, seguido de PM₁₀ (0.20) y las componentes temporales mes_sin y mes_cos (0.17 y 0.15 respectivamente), lo que evidencia una marcada estacionalidad en los niveles de calidad del aire de Bogotá. CO y hora_sin presentaron la menor contribución predictiva.




FIGURE 6. Importancia global de características SHAP

La Fig. 7 muestra el diagrama *beeswarm* para la categoría Buena (ICA 0-50), donde se observa que concentraciones elevadas de PM_{2.5} (puntos rojos) generan valores SHAP negativos, reduciendo la probabilidad de clasificación en esta categoría, mientras que concentraciones bajas (puntos azules) contribuyen positivamente. Este comportamiento es físicamente coherente con la norma colombiana de calidad del aire.




FIGURE 7. Diagrama beeswarm SHAP para categoría Buena

G. VISUALIZACIÓN ESPACIAL

Con el fin de comunicar los resultados del modelo de forma accesible, se desarrolló una **aplicación web** interactiva utilizando **Leaflet.js** y **HTML/CSS/JavaScript**. La aplicación despliega un mapa de Bogotá D.C. con las 19 estaciones de monitoreo de la RMCAB georreferenciadas mediante sus coordenadas oficiales, coloreadas según la categoría ICA predicha por el modelo Random Forest para el último registro disponible de cada estación. El mapa incluye un panel lateral con buscador por nombre de estación, ficha de detalle con el ICA histórico promedio y los valores normalizados de cada contaminante, y popups interactivos con vuelo automático a la estación seleccionada. La leyenda refleja las cinco categorías normativas definidas en la Resolución 2254 de 2017 [14]. La Fig. 8 presenta una captura de la visualización final.




FIGURE 8. Captura de la aplicación web de visualización espacial de riesgo respiratorio en Bogotá

La aplicación está disponible como página estática en el repositorio del proyecto [13], donde fue desplegada mediante GitHub Pages.

V. DISCUSIÓN DE RESULTADOS

Los resultados obtenidos en este estudio permiten contextualizar el **desempeño de los modelos** propuestos respecto al estado del arte en la predicción de la calidad del aire mediante técnicas de aprendizaje automático. A diferencia de la mayoría de los trabajos previos, que abordan este problema como una tarea de regresión para estimar concentraciones de contaminantes o valores numéricos del Índice de Calidad del Aire (ICA), la presente investigación lo plantea como una tarea de clasificación, prediciendo directamente cinco categorías ordinales de calidad del aire.

Random Forest obtuvo un desempeño ligeramente superior a **XGBoost** (Accuracy: 0.7827 vs. 0.7770; F1-weighted: 0.7693 vs. 0.7658). Esta tendencia coincide con los resultados reportados por Zhu et al. [10], quienes identificaron a RF como el modelo basado en árboles con mejor desempeño en la predicción de $PM_{2.5}$ y PM_{10} . Aunque dicho estudio aborda el problema como regresión y el presente trabajo como **clasificación ordinal del ICA**, la superioridad relativa de RF se mantiene en ambos casos. Una posible explicación es que el mecanismo de *bagging* de RF maneja mejor los **datos desbalanceados**, una característica relevante del conjunto de datos utilizado, donde las categorías de bajo riesgo concentran la mayoría de las observaciones.

Singh et al. [8] propusieron un **ensemble ponderado** para la predicción del AQI en Taiwán, obteniendo valores de R^2 superiores a 0.99. Sin embargo, esta diferencia respecto a los resultados del presente estudio se explica principalmente por la distinta formulación del problema: mientras su enfoque corresponde a una tarea de regresión sobre el valor continuo del AQI, este trabajo aborda una clasificación ordinal del ICA en cinco categorías. En este contexto, el F1-weighted de 0.7693 alcanzado por Random Forest representa un desempeño **competitivo**, especialmente considerando el marcado desbalance de clases del conjunto de datos, donde las categorías de mayor riesgo constituyen una fracción mínima de los registros.

El análisis **SHAP** confirmó que **$PM_{2.5}$** es la variable más influyente en la predicción del ICA, seguida por **PM_{10}** y las **variables estacionales** (mes_sin y mes_cos). Este hallazgo coincide con lo reportado por Zhu et al. [10], quienes también identificaron a $PM_{2.5}$ como el predictor más importante en modelos de contaminantes particulados. La marcada influencia de las variables temporales estacionales en el modelo de Bogotá refleja la **estacionalidad climática** de la sabana bogotana, donde los periodos secos concentran los episodios de mayor contaminación. Este comportamiento difiere del observado en estudios realizados en ciudades chinas y taiwanesas, cuyas condiciones climáticas presentan patrones distintos.

Un aspecto diferenciador de este trabajo es su **alcance geográfico**. Mientras Zhu et al. [10] y Singh et al. [8] utilizaron datos provenientes de extensas redes de monitoreo, el presente estudio se basa exclusivamente en las 19 estaciones de la **RMCAB** de Bogotá. Aunque esto implica una menor cobertura espacial, permite desarrollar

herramientas adaptadas al contexto local, incluyendo visualizaciones de riesgo respiratorio útiles para la **salud pública**. En este sentido, la **plataforma web** implementada y desplegada en GitHub constituye una contribución orientada a la **transferibilidad** de los resultados, un componente que no es abordado en los estudios de referencia.

VI. CONCLUSIONES

El presente estudio demostró que los modelos de aprendizaje automático basados en **árboles de decisión**, en particular Random Forest y XGBoost, constituyen **herramientas** efectivas para la clasificación del Índice de Calidad del Aire en Bogotá a partir de datos históricos de la RMCAB. Esto se confirma considerando que Random Forest alcanzó el mejor desempeño global (Accuracy: 0.7827, F1-weighted: 0.7693).

El análisis **SHAP** reveló que **PM_{2.5}** es el contaminante con mayor poder predictivo sobre la clasificación del ICA en Bogotá, con un valor medio de contribución absoluta de 0.58, seguido de PM₁₀ y los componentes estacionales. Este hallazgo tiene implicaciones directas para la gestión de la calidad del aire: las intervenciones de **política pública** orientadas a reducir las concentraciones de PM_{2.5} tendrán el mayor impacto sobre el riesgo respiratorio de la población bogotana.

La marcada **estacionalidad** identificada en el modelo, expresada en la alta importancia de las variables `mes_sin` y `mes_cos`, confirma que los periodos secos del año concentran los episodios de mayor riesgo respiratorio en la ciudad, lo que subraya la necesidad de implementar **sistemas de alerta temprana** que anticipen estos ciclos.

Finalmente, la integración de los resultados del modelo con la **visualización geoespacial interactiva** desplegada en GitHub Pages [13] demuestra el potencial de este enfoque como herramienta de apoyo a la toma de decisiones para planificadores urbanos y autoridades de salud pública en Bogotá.

VII. RECOMENDACIONES

A partir de los hallazgos y limitaciones identificadas en este estudio, se plantean las siguientes recomendaciones para investigaciones futuras:

Estrategias de manejo del desbalance de clases. El bajo recall en las categorías de mayor riesgo (Dañina y Muy dañina) constituye la limitación técnica más relevante del modelo actual. Se recomienda explorar técnicas de sobremuestreo sintético como SMOTE (Synthetic Minority Oversampling Technique), así como el ajuste de pesos de clase en los hiperparámetros de los modelos (`class_weight`), con el objetivo de mejorar la sensibilidad del sistema.

Incorporación de variables meteorológicas. El presente estudio se limitó a variables de contaminantes atmosféricos y codificaciones temporales. La inclusión de variables meteorológicas como temperatura, humedad relativa y precipitación podría mejorar sustancialmente la capacidad predictiva del modelo, tal como evidencian Zhu et al. [10] y Karim et al. [3], quienes reportaron mejoras significativas al integrar estas variables en sus marcos predictivos.

Extensión hacia modelos de regresión del ICA numérico. Reformular el problema como una tarea de regresión del ICA permitiría realizar comparaciones más directas con otros trabajos y proporcionar estimaciones con mayor granularidad. Un enfoque híbrido que combine regresión y clasificación podría resultar especialmente útil para sistemas de alerta temprana.

Validación temporal y generalización espacial. Los datos empleados abarcan los años 2024 y 2025. Se recomienda extender el horizonte temporal para capturar variabilidad interanual y evaluar si los modelos mantienen su desempeño ante condiciones atípicas como fenómenos climáticos extremos (El Niño/La Niña). Adicionalmente, el esquema podría adaptarse a otras ciudades colombianas con redes de monitoreo activas, como Medellín o Cali, para evaluar su transferibilidad.

Incorporación de datos de salud. El objetivo final del sistema es predecir la propensión a enfermedades respiratorias, no únicamente clasificar la calidad del aire. La integración de datos de consultas médicas y hospitalizaciones por causas respiratorias permitiría validar externamente los mapas de riesgo generados y cerrar el ciclo metodológico entre contaminación atmosférica y salud pública, siguiendo el enfoque de Telesca y Rondinone [11].

REFERENCIAS

- [1] J. Bernacki and R. Scherer, "A comprehensive review of data-driven techniques for air pollution concentration forecasting," *Sensors*, vol. 25, no. 19, p. 6044, 2025, doi: 10.3390/s25196044.
- [2] A. Bekkar, B. Hssina, S. Douzi, and K. Douzi, "Air-pollution prediction in smart city, deep learning approach," *Journal of Big Data*, vol. 8, p. 161, Dec. 2021, doi: 10.1186/s40537-021-00548-1.
- [3] M. Karim, S. Tomar, S. K. Shah, and T. P. Singh, "Analyzing and predicting PM₁₀ using remote sensing and machine learning: A case study of Delhi, India," *Discover Applied Sciences*, vol. 7, p. 1291, Oct. 2025, doi: 10.1007/s42452-025-07818-0.
- [4] N. S. Mwase, M. Kebalepile, W. Junger, and J. Wichmann, "Unsupervised machine learning to investigate the joint effects of SO₂, NO₂, O₃, PM_{2.5} and PM₁₀ on respiratory and cardiovascular hospital admissions in the Vaal Triangle Airshed Priority Area, South Africa," *Atmospheric Environment*, vol. 366, p. 121660, 2026, doi: 10.1016/j.atmosenv.2025.121660.
- [5] J. Morales-García, E. Ramos-Sorroche, S. Balderas-Díaz, G. Guerrero-Contreras, A. Muñoz, J. Santa, and F. Terroso-Sáenz, "Reducing pollution health impact with air quality prediction assisted by mobility data," *IEEE Journal of Biomedical and Health Informatics*, vol. 29, no. 12, pp. 9210-9220, Dec. 2025, doi: 10.1109/JBHI.2024.3508466.
- [6] I. Ahmadianfar, Z. M. Yaseen, H. A. Marhoon, B. Halder, M. L. Tan, H. C. Kilinc, S. I. Abba, S. Heddami, L. Goliati, V. Demir, and A. M. Al-Areeq, "Towards intelligent air quality forecasting using integrated machine learning framework with variational mode decomposition and catboost feature selection," *Sci. Rep.*, vol. 16, art. 3714, 2026, doi: 10.1038/s41598-025-33785-y.
- [7] M. Daniyal, H. Alyami, A. J. Alqahtani, M. Talha, A. Rahman, and A. Al Mutair, "Modeling and forecasting air pollution for public health protection based on ML and time series models in Gulf Cooperation Council (GCC) countries," *BMC Public Health*, vol. 26, art. 280, 2026, doi: 10.1186/s12889-025-26164-9.
- [8] S. Singh, M. Kumar, V. Sengar, A. Kumar, K. Abhishek, and B. M. A. Shafeeq, "Ensemble learning for air quality index prediction: integrating gradient boosting, XGBoost, and stacking with SHAP-based interpretability," *Sci. Rep.*, vol. 16, art. 8544, 2026, doi: 10.1038/s41598-026-39232-w.
- [9] D. Han, M. Wang, Y. Xiang, T. Zhang, J. Liu, and Y. Tan, "Remote sensing-based PM_{2.5} inversion and explainable AI analysis of urban environmental drivers in Harbin," *Sustainable Cities and Society*, vol. 141, p. 107287, 2026, doi: 10.1016/j.scs.2026.107287.
- [10] X. Zhu, B. Li, Y. Cao, and Q. Zhang, "Applicability analysis of tree-based ensemble learning for air pollutant prediction models," *Sci. Rep.*, vol. 16, p. 3309, Feb. 2026, doi: 10.1038/s41598-025-32652-0.
- [11] V. Telesca and M. Rondinone, "Ensemble machine learning model to analyse the correlation between environmental features and respiratory admissions in the emergency room," in *Computational Science and Its Applications – ICCSA 2025 Workshops*, Lecture Notes in Computer Science, vol. 15898. Springer, 2026, pp. 417–429, doi: 10.1007/978-3-031-97657-5_27.
- [12] Secretaría Distrital de Ambiente, "Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB)," Bogotá, Colombia. [En línea]. Disponible en: <http://rmcab.ambientebogota.gov.co>
- [13] N. Parra Ariza, "respiratory-risk-bogota: Predictive analysis of respiratory risk in Bogotá using RMCAB air quality data," GitHub, 2026. [En línea]. Disponible en: <https://github.com/NickolaiParra/respiratory-risk-bogota>
- [14] Ministerio de Ambiente y Desarrollo Sostenible, "Resolución 2254 de 2017, por la cual se adopta la norma de calidad del aire ambiente y se dictan otras disposiciones," Bogotá D.C., Colombia, Nov. 1, 2017. [En línea]. Disponible en: <https://www.minambiente.gov.co/documento/resolucion-2254>